

ABEJORROS

June Castro, Iker Fuente, David Miguez, Daniel Talmaci

Clasificación tradicional

Datos

1. Corrección csv (columnas y comas)
2. Separación en:
 - a. Train: 70%
 - b. Dev: 15%
 - c. Test: 15%

Preproceso

1. Limpieza de datos
2. Conversión de etiquetas
3. Tratamiento de texto y emojis
4. Protección de palabras importantes
5. Vectorización
6. Escalado

Balanceo

1. Oversampling con SMOTE

Trucos

1. Uso de bigramas
2. Sustitución de emojis por su descripción

Modelos Implementados

1. k-Nearest Neighbors (kNN)
2. Decision Tree
3. Random Forest
4. Naive Bayes
5. Logistic Regression
6. Support Vector Machine (SVM)

Mejores Resultados SIN Balanceo

Algoritmo	Hiperparámetros	F1_score
Naïve_Bayes	alpha: 0.01	0.5592
Naïve_Bayes	alpha: 0.1	0.5426
Decision_Tree	Gini, max_depth=7, min_samples_leaf=5, min_samples_split=5	0.4697

Mejores Resultados CON Balanceo

Algoritmo	Hiperparámetros	F1_score	Oversampling
Logistic_regression	c=1, calss_weight=balanced, max_iter=1000, penalty=L2	0.6151	Smote
Naïve_Bayes	alpha: 0.5	0.6148	Smote
Logistic_regression	c=0.5, calss_weight=balanced, max_iter=1000, penalty=L2	0.6132	Smote
Naïve_Bayes	alpha: 0.01	0.5909	Generativo
Naïve_Bayes	alpha: 0.1	0.5849	Generativo

Clustering LDA + K-Means

Preproceso:


Stopwords

Stemming

Emojis

Bigramas


Vectorización (BoW / TF-IDF)



Reseñas cortas (≤ 5 palabras)

K-Means con TF-IDF.

Valor óptimo $K=3$ mediante método del codo.



Reseñas largas (>5 palabras)

Latent Dirichlet Allocation (LDA) con Bag of Words.
Pico máximo en $K=4$ maximizando la coherencia (Cv).

Modelo	Sentimiento	Tópico	Palabras Clave
LDA	Negativo	Limitaciones uso gratis (cluster 1)	pay, premium, free, messag, money
LDA	Negativo	Paywall y costes (clusters 0 y 3)	account, subscript, paywall, charg
K-Means	Positivo	Elogios y satisfacción general (clusters 2 y 5)	great, love, best, enjoy, found, messag
LDA	Positivo	Optimismo y buen servicio (cluster 4)	great, met, found, better, servic

Modelo generativo

llama3.1_OneShot_Prompt:

F1 Macro: 0.6429

You are an expert data analyst for the Bumble dating app. Classify the sentiment of the following app review into exactly one of these three categories: Positive, Neutral, or Negative. Do not add any extra words, punctuation, or explanations. Just output the category name.

Text: I hate that I have to pay for everything on this app now.
Your response (one word only): Negative

Text: Met my husband here 2 years ago, best decision ever!
Your response (one word only): Positive

Text: It works okay, but sometimes messages take a while to load.
Your response (one word only): Neutral

Modelos utilizados:

llama3.1
gemma2:2b-text-q4_K_S
qwen2.5:7b
granite4:350m-h

Hiperparámetros utilizados:

```
model = OllamaLLM(  
    model=name,  
    temperature=0, # creatividad  
    num_predict=20, # max_tokens  
    repeat_penalty=1.1, # penalización  
    top_k=10, # tamaño del vocabulario candidato  
    top_p=0.5 # masa de probabilidad acumulada  
)
```